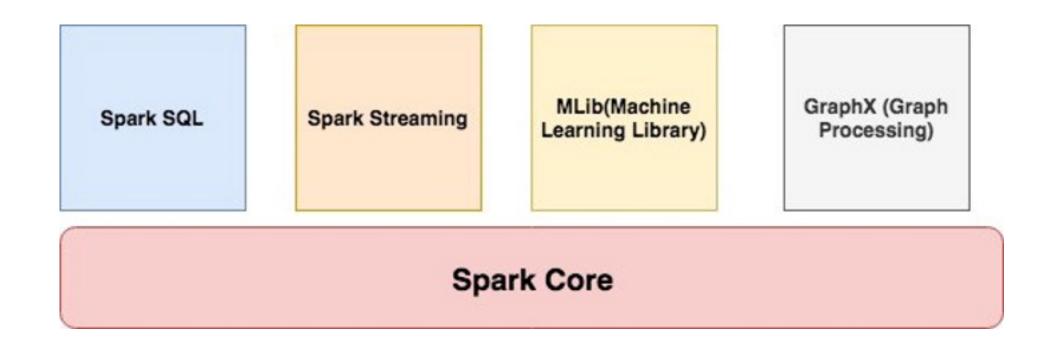
# DATABRICKS

Inteligencia de Negocio 13 de octubre de 2023

#### **SPARK**



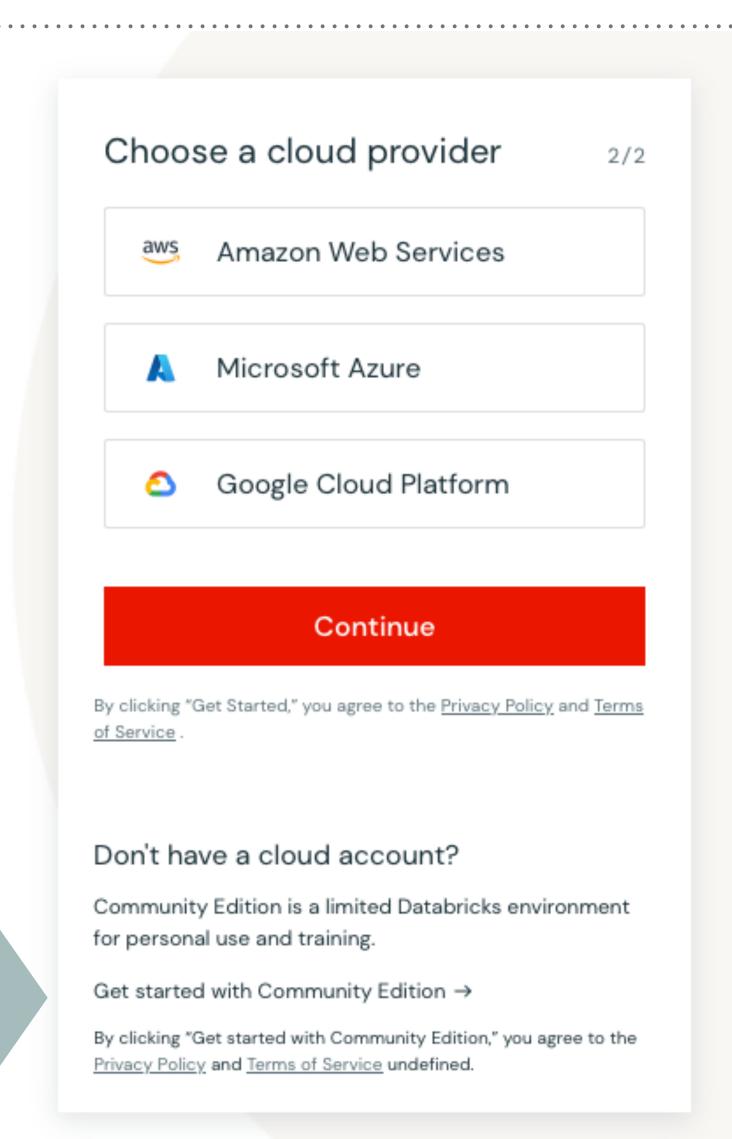
- ➤ Apache Spark es un framework de computación (entorno de trabajo) en clúster en código abierto. Proporciona una interfaz para la programación de clusters completos con Paralelismo de Datos implícito y tolerancia a fallos.
- ➤ Se puede considerar un sistema de computación en clúster de propósito general y orientado a la velocidad. Proporciona APIs en Java, Scala, Python y R. También proporciona un motor optimizado que soporta la ejecución de gráficos en general. También soporta un conjunto extenso y rico de herramientas de alto nivel entre las que se incluyen Spark SQL (para el procesamiento de datos estructurados basada en SQL), MLlib para implementar machine learning, GraphX para el procesamiento de graficos y Spark Streaming.

#### PYSPARK Y DATABRICKS

- ➤ Databricks es un entorno que permite utilizar notebooks en PySpark para definir los pipelines con el flujo de datos en los procesos ETL
- ➤ Usamos la Community Edition de Databricks, que permite crear clusters Spark gratuitos.
- ➤ Para poder conectar Databricks con herramientas de acceso como Power Bi de Microsoft necesitaríamos un conector que solamente está disponible en las ediciones de pago de Databricks
- https://docs.databricks.com/en/getting-started/community-edition.html

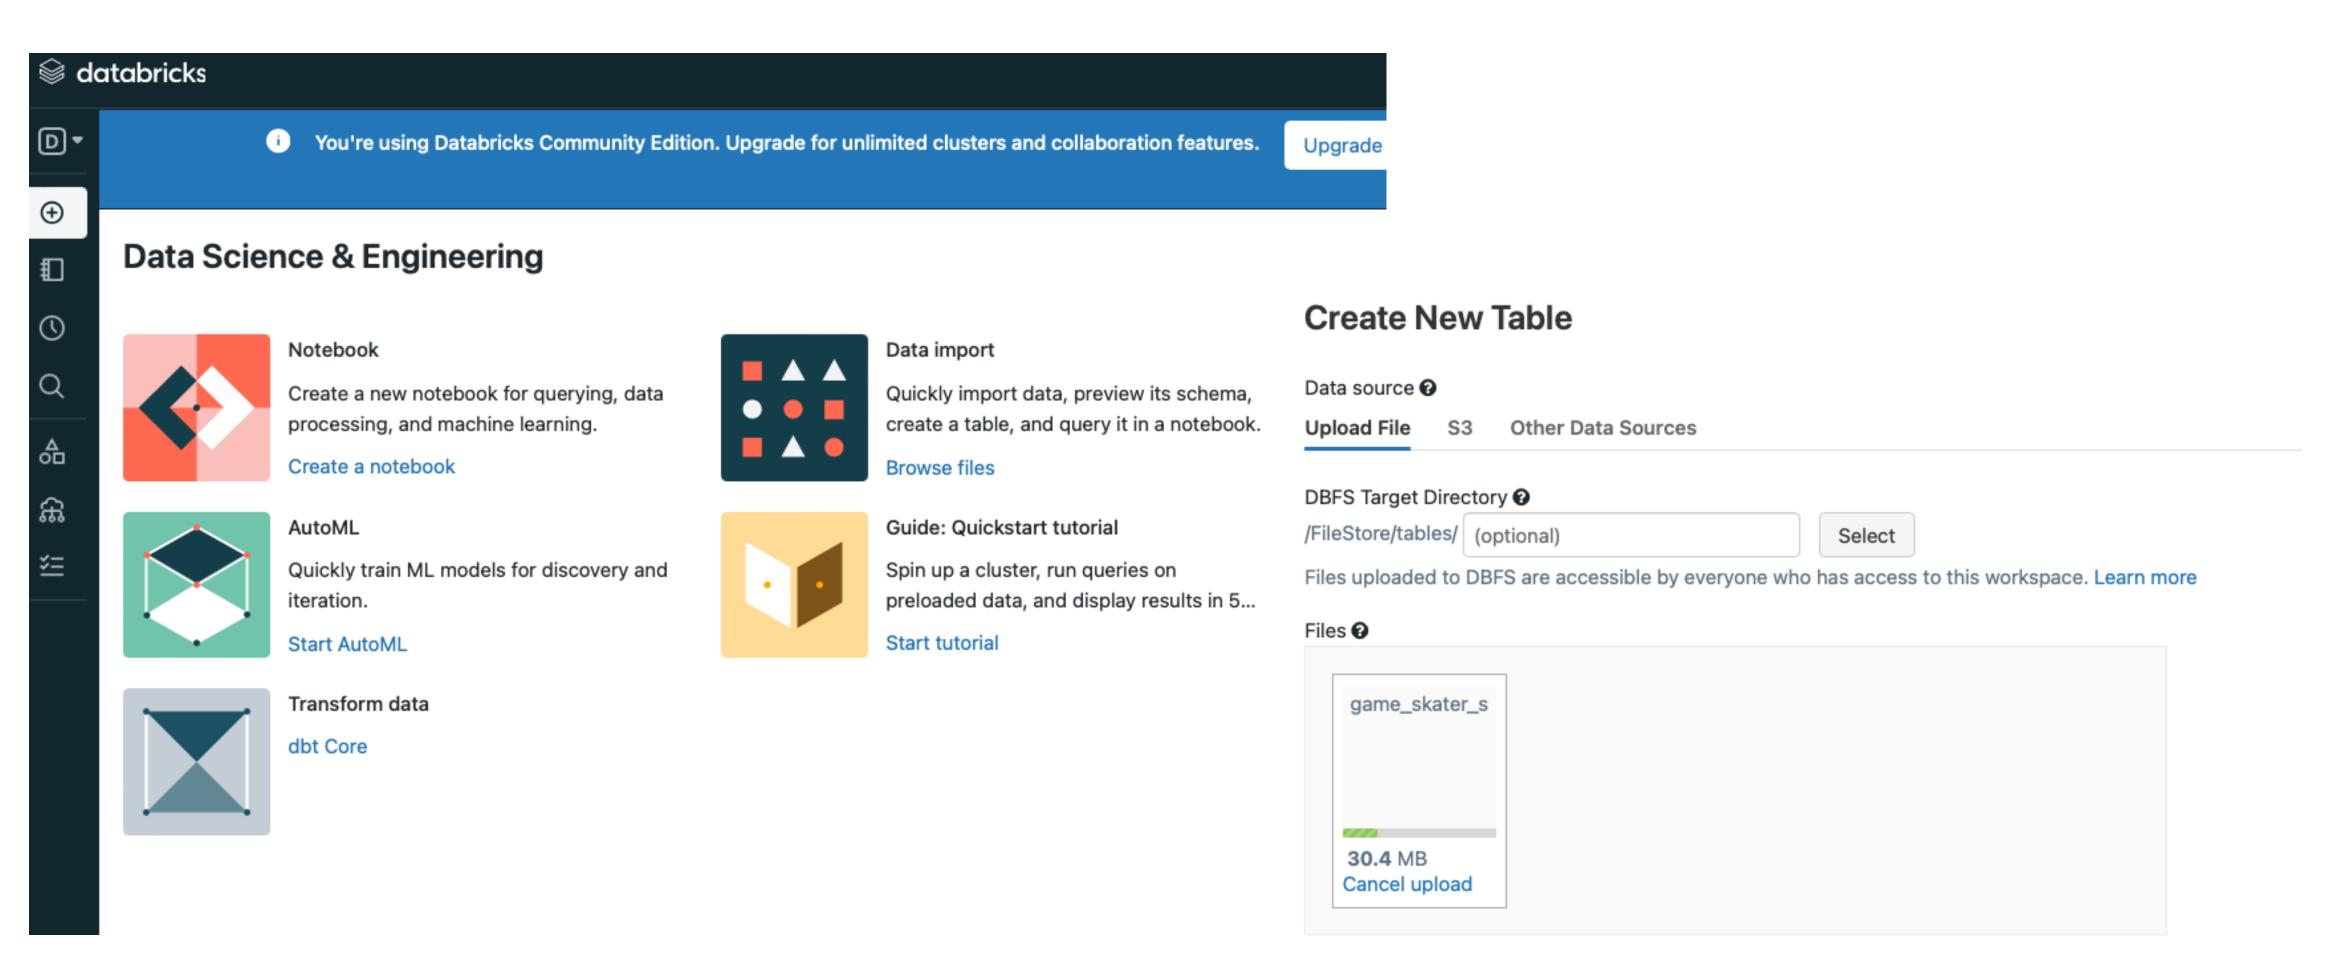
## NUEVA CUENTA EN COMMUNITY EDITION

https://community.cloud.databricks.com/ login.html



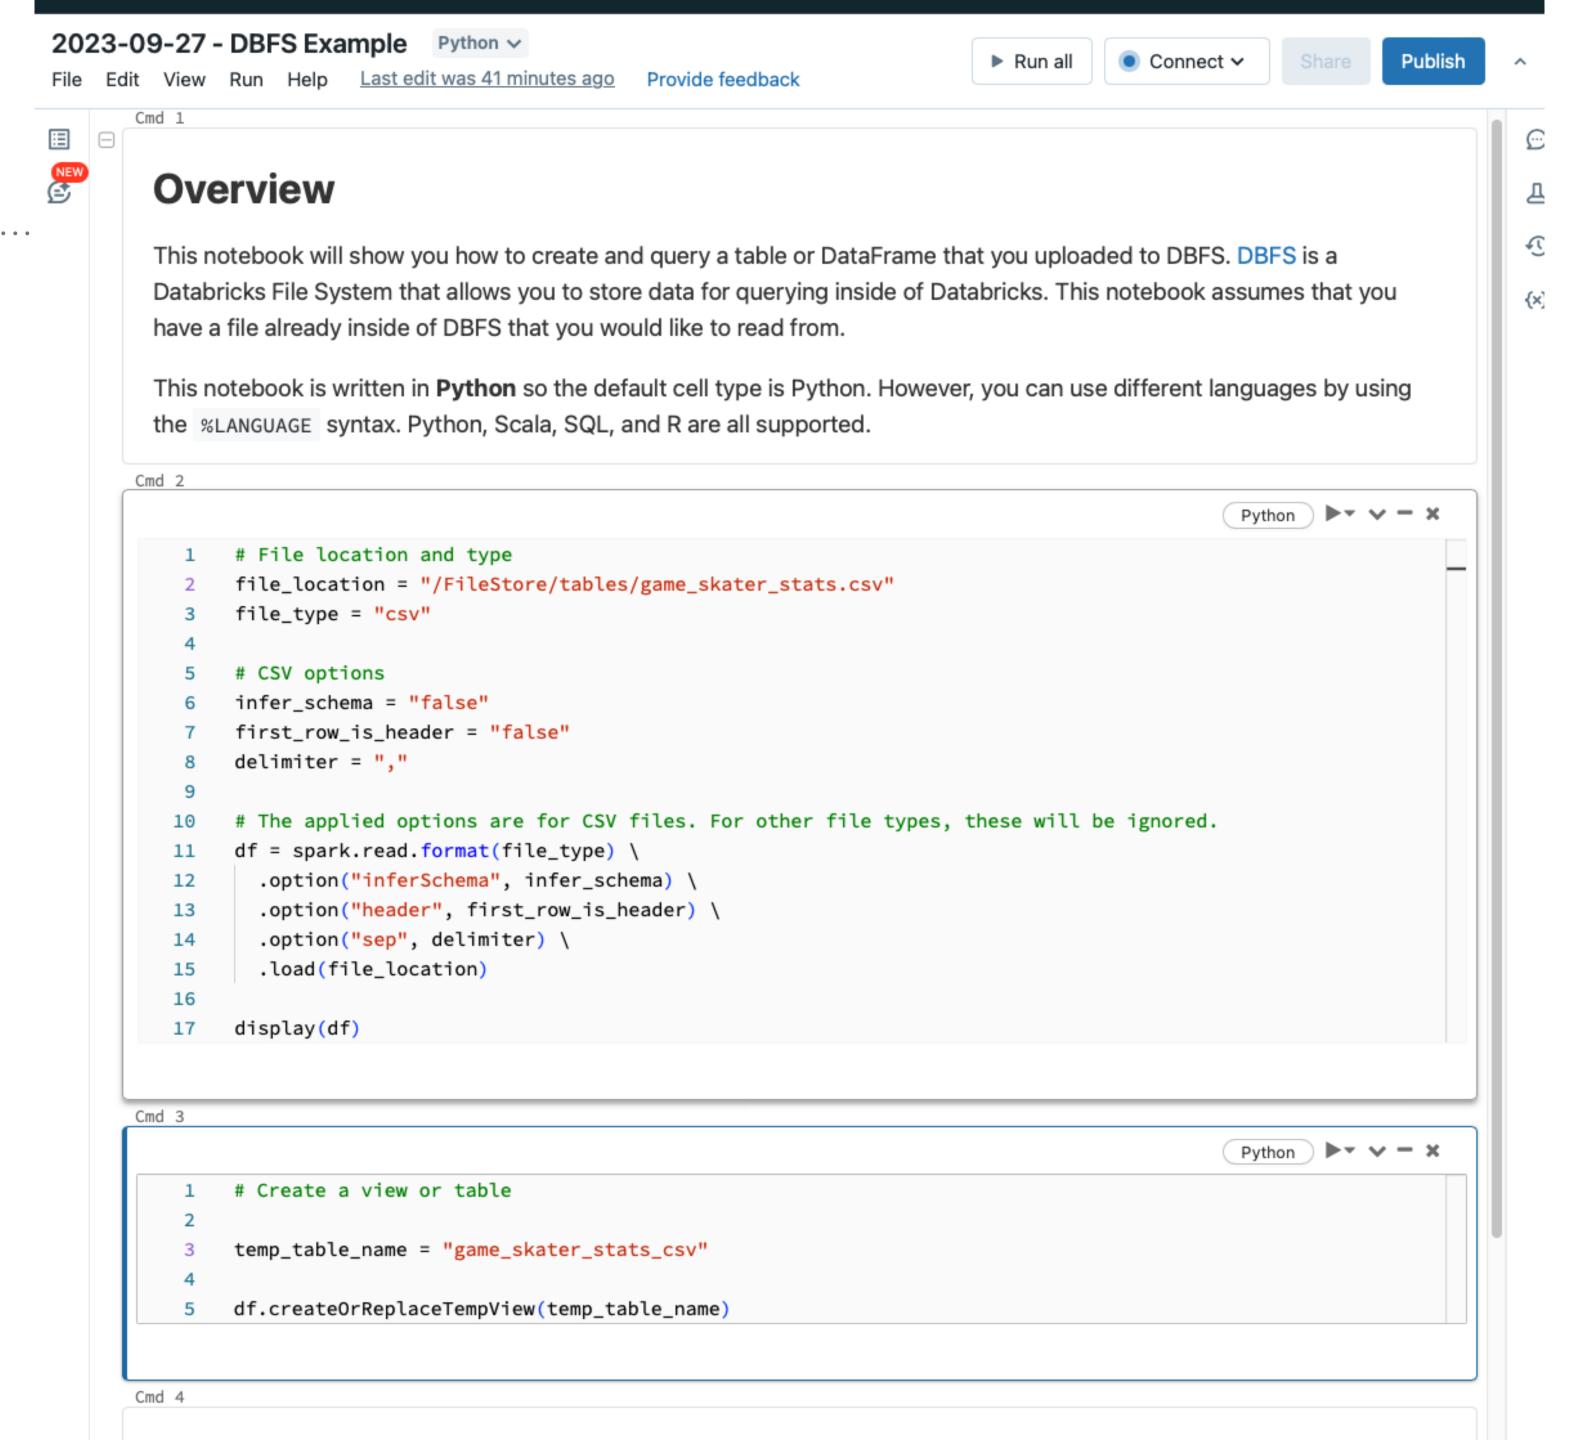
### SUBIDA DE DATOS

Subimos archivo "game\_skater\_stats.csv"

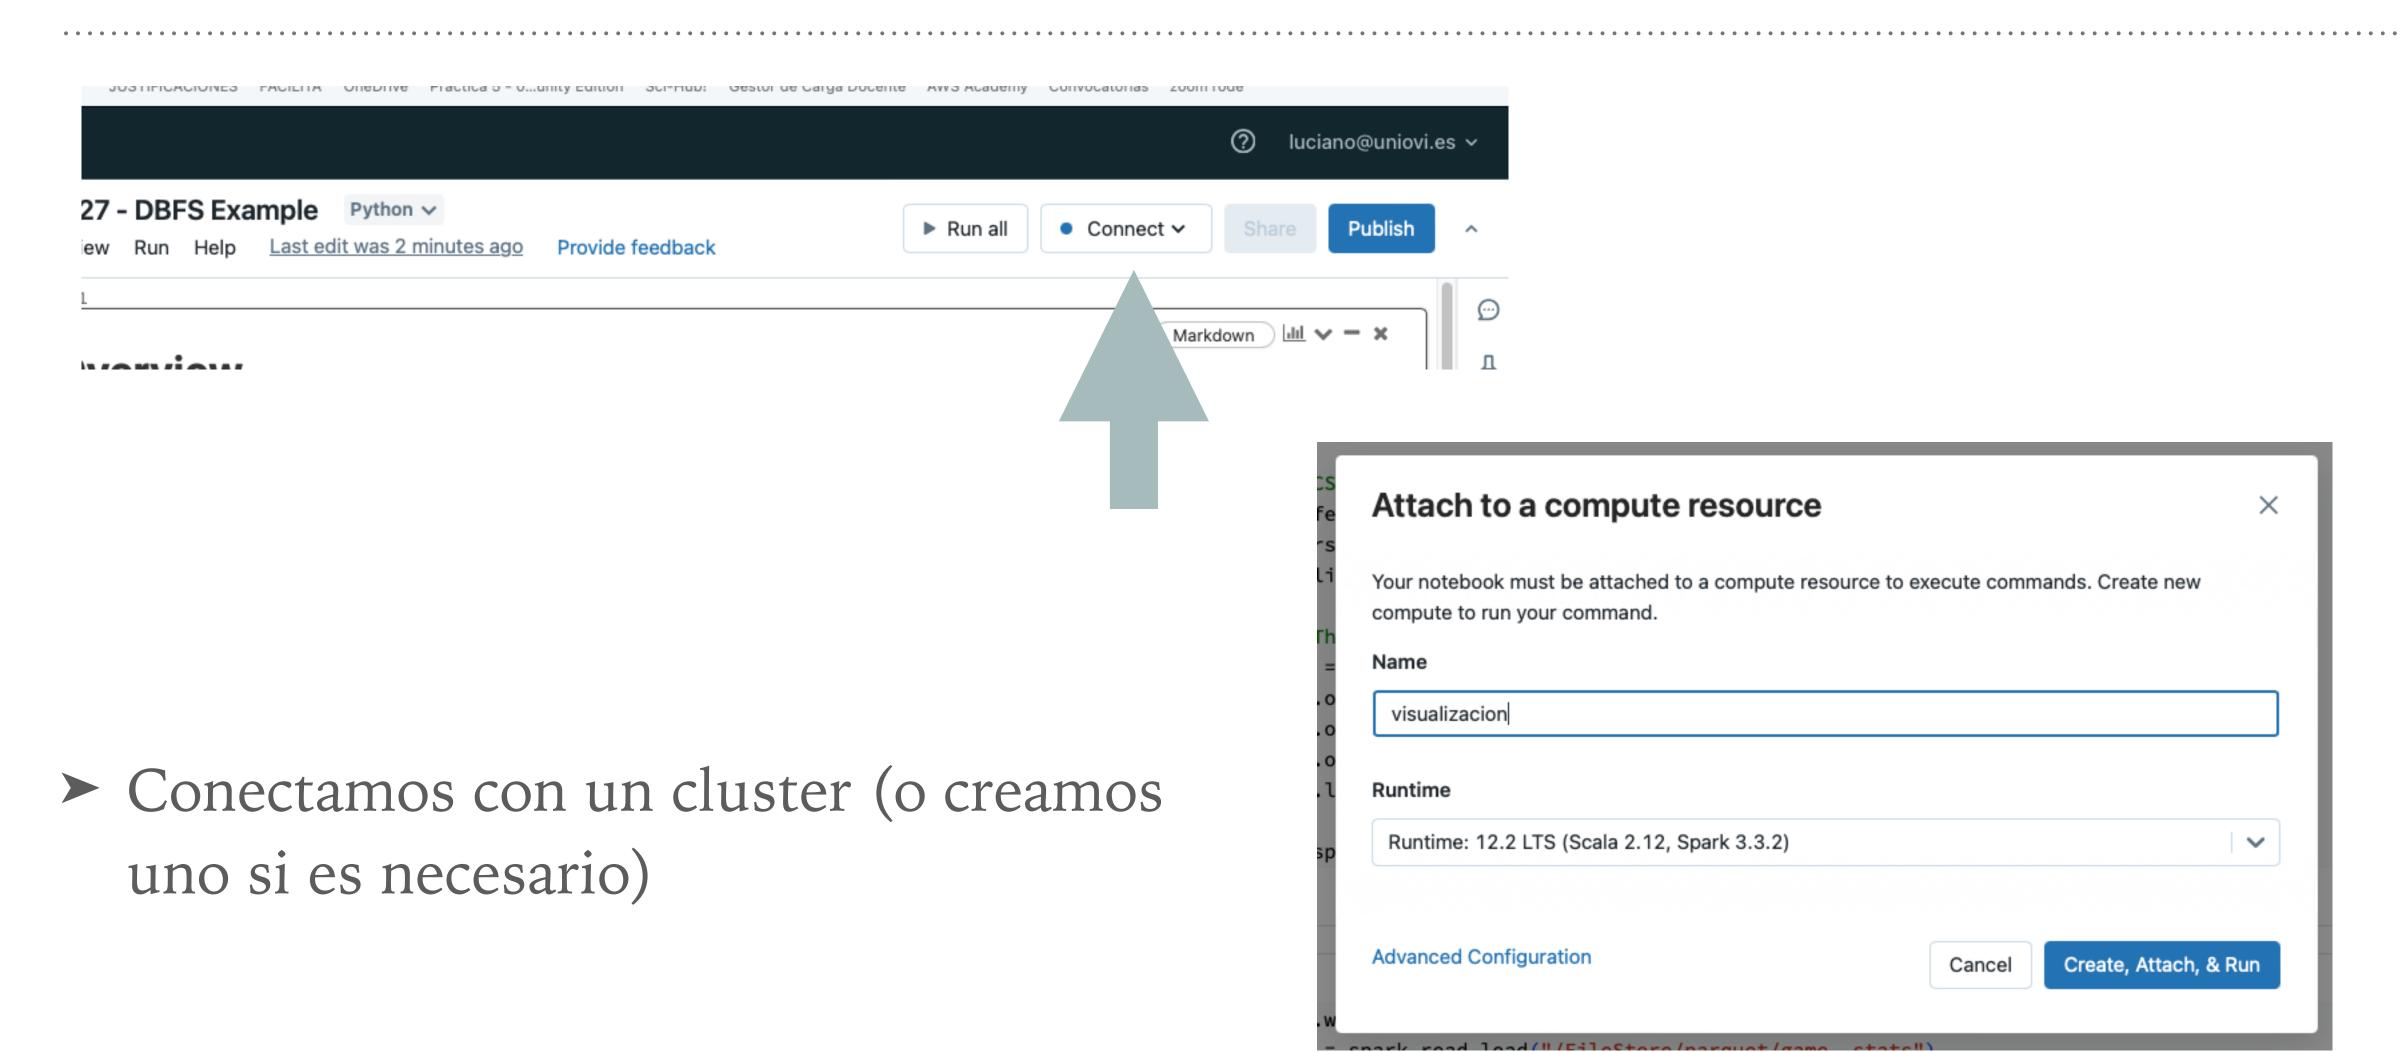


#### **NOTEBOOK**

- Creamos un notebook con acceso a la table
- ➤ Cambiamos infer\_schema y first\_row\_is\_header a True
- ➤ Borramos celdas de la tercera en en adelante



# SOLICITAMOS CLUSTER DE CÓMPUTO



# EJECUTAMOS CELDAS Y AÑADIMOS CONTENIDO

- ➤ Ver archivo ParteGuiada.py con el contenido de las celdas que iremos pegando en el notebook
- Las celdas no se ejecutan en un único servidor, sino que se paraleliza el trabajo entre las máquinas del cluster
- Tampoco usamos Dataframes en memoria, sino que se accede a un sistema de archivos que también está paralelizado
- ➤ Es posible convertir una vista de la base de datos en un Dataframe Pandas, pero en ese momento se restringe la ejecución a un único nodo (el que tiene el Dataframe en el memoria) y se pierde la capacidad de Spark de trabajar en paralelo con grandes volúmenes de datos

#### CARGAR CSV EN LA BASE DE DATOS DISTRIBUIDA

- > Se graba el contenido del objeto df en formato delta
- https://docs.databricks.com/en/introduction/delta-comparison.html
- ➤ df no es un Dataframe pandas, sino un objeto pySpark con un interfaz de acceso similar (pero no exactamente igual)
- > df tampoco está en memoria en un nodo; es un enlace a la base de datos distribuida

## VECTORASSEMBLER

```
1 # Create a vector representation for features
2 assembler = VectorAssembler(inputCols=['shots', 'hits', 'assists',
3 | 'penaltyMinutes','timeOnIce','takeaways'],outputCol="features")
4 train_df = assembler.transform(df)

Image: by luciano@uniovi.es at 27/09/2023, 11:06:25 on visualizacion
```

- ➤ En sklearn, la mayoría de los modelos pueden tomar DataFrames sin procesar como entrada para el entrenamiento. En un entorno distribuido es un poco más complicado: se utilizan Assemblers para preparar nuestros datos de entrenamiento.
- ➤ VectorAssembler (librería Spark ML) es un módulo que permite convertir características numéricas en un único vector que es utilizado por los modelos de machine learning.
- ➤ A modo de resumen, lo que hace es tomar una lista de columnas (características) y combinarla en una única columna vectorial (vector de características). A continuación, se utiliza como entrada en los modelos de aprendizaje automático en Spark ML.

## MODELO DE MACHINE LEARNING

```
| # Fit a linear regression model
| 2 | lr = LinearRegression(featuresCol = 'features', labelCol='goals')
| 3 | lr_model = lr.fit(train_df)
| (2) Spark Jobs
| Command took 14.92 seconds -- by luciano@uniovi.es at 27/09/2023, 11:09:11 on visualizacion
| Cmd 8 | Python | Pv v = x |
| 1 | trainingSummary = lr_model.summary
| 2 | print("Coefficients: " + str(lr_model.coefficients))
| 3 | print("RMSE: %f" % trainingSummary.rootMeanSquaredError)
| 4 | print("R2: %f" % trainingSummary.r2)
| Coefficients: [0.09353643668143533, -0.006632536309343135, 0.005487355356078061, -0.000177792345791571, -4.317801186|
| 031907e-05, 0.017566692293079472 |
| RMSE: 0.378003 |
| R2: 0.126676 |
| Command took 0.20 seconds -- by luciano@uniovi.es at 27/09/2023, 11:11:58 on visualizacion
```

➤ Se le indica al algoritmo de ML el nombre del vector que contiene los datos de entrada ('features') y se le proporciona el nombre del vector que contendrá los datos de salida ('goals')

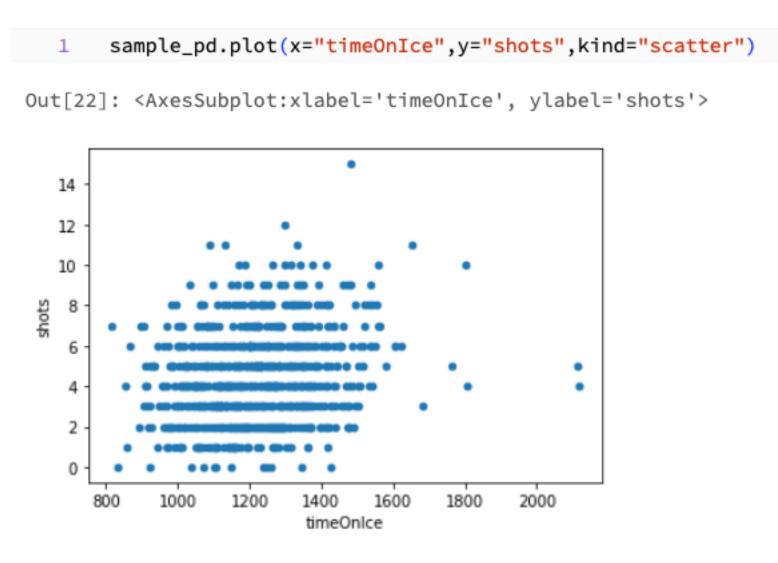
## USO DE PIPELINES (ETL)

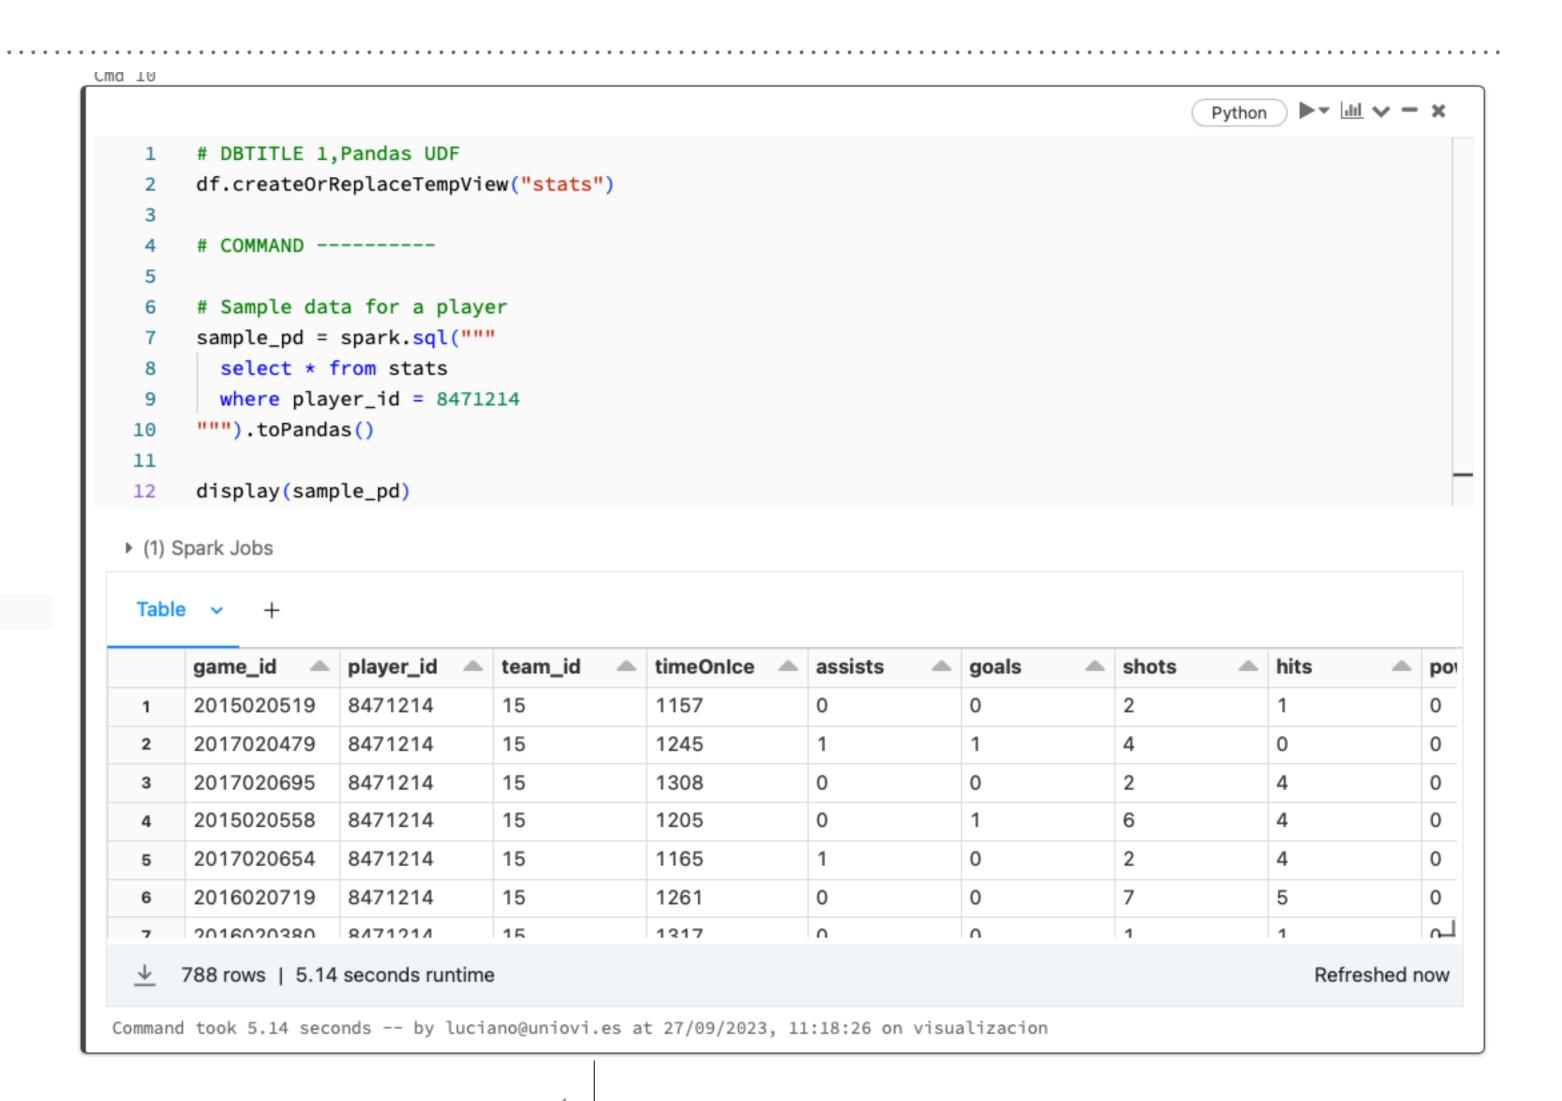
- ➤ Un pipeline es una secuencia de transformaciones realizadas sobre unos datos
- En este ejemplo, el pipeline contiene la creación del VectorAssembler y el aprendizaje del modelo

```
# Regresion mediante arboles de decision
       from pyspark.ml import Pipeline
       from pyspark.ml.regression import RandomForestRegressor
       from pyspark.ml.evaluation import RegressionEvaluator
       (trainingData, testData) = df.randomSplit([0.7, 0.3])
       # Crea un dataframe con las columnas que necesitamos
       assembler = VectorAssembler(inputCols=['shots', 'hits', 'assists',
           'penaltyMinutes', 'timeOnIce', 'takeaways'], outputCol="features")
       # Modelo de regresion
       rf = RandomForestRegressor(featuresCol='features',labelCol='goals')
 13
       # Pipeline: assembler -> random forest
       pipeline = Pipeline(stages=[assembler,rf])
 16
       # Lanzamos el pipeline
       model = pipeline.fit(trainingData)
 19
       # Evaluacion en el conjunto de test
       predictions = model.transform(testData)
 22
       # Medicion del ajuste
       evaluator = RegressionEvaluator(
           labelCol="goals", predictionCol="prediction", metricName="rmse")
 25
       rmse = evaluator.evaluate(predictions)
 27
       evaluator2 = RegressionEvaluator(
           labelCol="goals", predictionCol="prediction", metricName="r2")
       r2 = evaluator2.evaluate(predictions)
       print("R2 on test data = %g" % r2)
 32
(10) Spark Jobs
trainingData: pyspark.sql.dataframe.DataFrame = [game_id: integer, player_id: integer ... 20 more fields]
▶ ■ testData: pyspark.sql.dataframe.DataFrame = [game_id: integer, player_id: integer ... 20 more fields]
 predictions: pyspark.sql.dataframe.DataFrame = [game_id: integer, player_id: integer ... 22 more fields]
R2 on test data = 0.123073
Command took 40.06 seconds -- by luciano@uniovi.es at 27/09/2023, 11:13:53 on visualizacion
```

# EXPORTACIÓN A PANDAS

sample\_pd es un DataFrame pandas, las operaciones que se realicen sobre él no se paralelizan

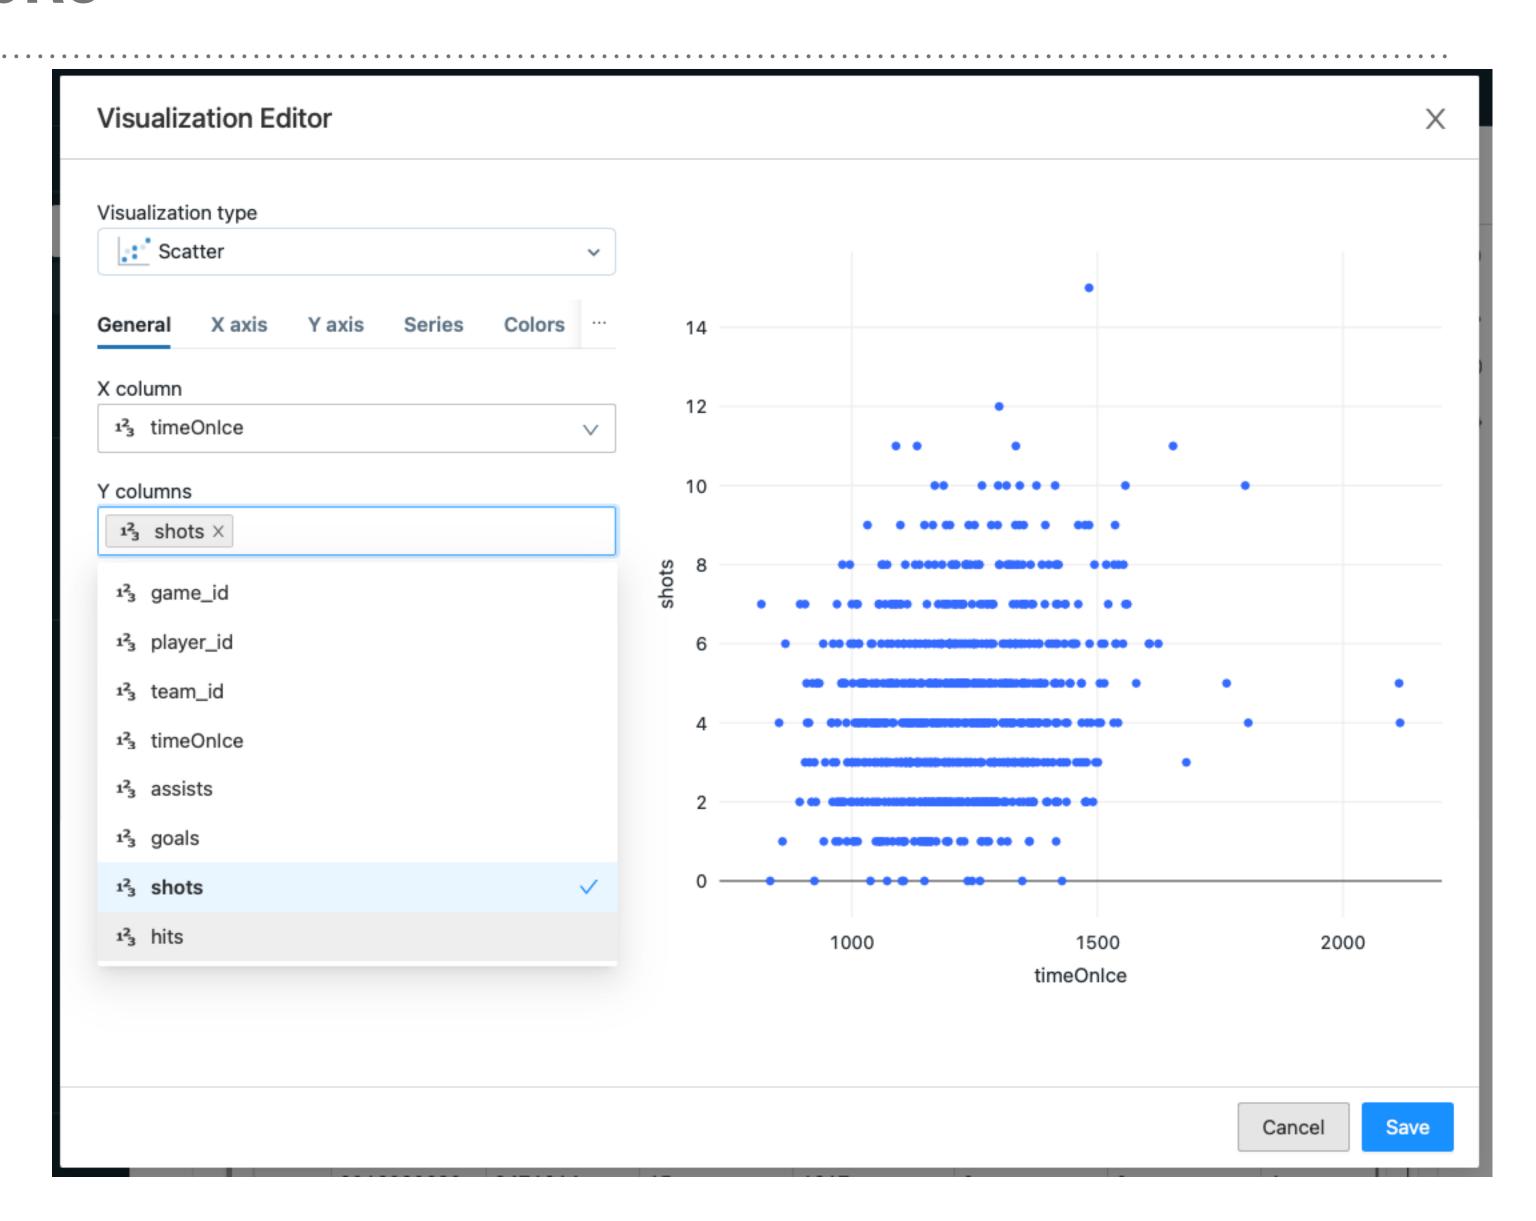




Command took 0.41 seconds -- by luciano@uniovi.es at 27/09/2023, 11:22:43 on visualizacion

## VISUALIZACIONES EN DATABRICKS

- ➤ En la ventana de visualización de cualquier consulta a la base de datos se puede lanzar el editor de visualizaciones
- Las visualizaciones pueden añadirse a dashboards



sample\_spark = spark.sql(""" select \* from stats where player\_id = 8471214 display(sample\_spark) ▼ (3) Spark Jobs ▶ Job 39 View (Stages: 1/1) ▶ Job 40 View (Stages: 1/1) ▶ Job 41 View (Stages: 1/1) ▶ ■ sample\_spark: pyspark.sql.dataframe.DataFrame = [game\_id: integer, player\_id: integer ... 20 more fields] Visualization 1 V + Table 16 14 12 10 1000 1200 1400 1600 1800 2000 800 timeOnIce Edit Visualization 788 rows Refreshed 3 minutes ago Command took 2.33 seconds -- by luciano@uniovi.es at 27/09/2023, 11:36:07 on visualizacion

